1. 매일 00:30, 12:30, 16:30에 수집기간의 날짜를 파일명으로 사용한 데이터 파일이 메일로 전달됨.
   발신: spam@strato.co.kr / 제목: [스팸필터링] – 육안분석요청(2025년 11월 27일 데이터)
   - *History.01*(2024.10.18 적용)
     . 기존에는 00:30에 전달되었으나, 배포되는 메시지에 스팸_score를 추가함으로써 작업파일의 생성 시간 증가로 인해 03:00로 배포시간이 늦춰짐.
     . 작업대상 파일도 AI_saint_Analysis_Result_20251127.zip으로 변경됨.
   - *History.02*(2025.12.01 부터 적용)
     . 작업 데이터 수신: 현재 "1회/일" → "3회/일"로 변경됨
     . 작업 데이터 수신 시각: 현재 03:00 수신 → 12:30, 16:30, 00:30(익일)으로 변경.
     . 작업 파일 이름의 구분: 현재 날짜로 구분 → 데이터수집 구간에 따라 시간순 _A, _B, _C와 같은 timeOrder를 붙여서 구분.
       - 12:30 수신("_A"), 16:30 수신("_B"), 00:30 수신("_C")
         예) 2025년 11월 27일 00:30에 수신된 파일 : 20251126_C
         2025년 11월 27일 12:30에 수신된 파일 : 20251127_A
     . 결과 데이터 배포: 현재 익일 14:00 이전 → 각각 당일 18:00, 익일 10:00, 익일 14:00로 변경
     . 결과 데이터 파일 이름 변경:
       - 현재 MMSC스팸추출_20251127(최종).xlsx → MMSC스팸추출_20251127_A.xlsx

(2025.11.31까지)

횟수	신고데이터 수집구간	학습 건수	전달 시각	태깅 작업 시간	배포 시각
1	전일 00:00 ~ 23:59	2,500	당일 03:00	당일 09:00 ~ 익일 14:00	익일 14:00

(2025.12.01부터)

횟수	신고데이터 수집구간	학습 건수	전달 시각	태깅 작업 시간	배포 시각
1	당일 00:00 ~ 12:00	1,900	당일 12:30	당일 12:30 ~ 당일 18:00	당일 18:00
2	당일 12:00 ~ 16:00	1,900	당일 16:30	당일 16:30 ~ 익일 10:00	익일 10:00
3	당일 16:00 ~ 00:00	2,200	익일 00:30	익일 00:30 ~ 익일 14:00	익일 14:00

(전달 시각: 태깅_요청_데이터 수신 시각, 배포시각: 태깅_결과 발송 시각)

2. 이하, 2025년 11월 27일 12:30에 수신되었다고 가정하고, 파일에 사용되는 날짜를 20251127_A로 예시함. 수신된 육안분석요청 파일의 데이터(*.zip 파일 내부의 text 파일들)를 작업하여 최종_결과인 "MMSC스팸추출_20251127_A.xlsx" 파일을 당일 18:00에 배포해야 함.

결과물로 배포되어야 하는 데이터 (즉, MMSC스팸추출_20251127_A.xlsx 파일에 포함되어야 함)
- 메시지의 **스팸 여부**와 **스팸 종류** - URL이 있는 스팸메시지의 **스팸 URL** - URL이 없는 스팸메시지에서 추출한 **스팸 문자열**(공백이 제거된 길이 9bytes ~ 20bytes의 strings) - URL이 없는 스팸메시지 중, 문자열을 생성하지 못한 잔여 스팸메시지에서 추출한 **스팸 문장**(공백이 제거된 길이 39bytes ~ 40bytes의 strings) - 매일 발생되는 **금융.spam 데이터**(메시지 내용만 필요함)

3. 육안분석 요청 메일에는 아래 두 개의 파일이 첨부되며, tagging_org_20251127_A.zip 파일만 사용함.
   - tagging_org_20251127_A.zip : 태깅작업 + MMSC원문_데이터 파일 처리(뒤쪽에 기술)에 사용
   - tagging_ref_20251127_A zip : 사용 안 함

4. tagging_org_20251127_A.zip 파일에 포함된 text 파일을 사용하여 작업함(아래 표 참고).

파일 이름	사용 여부	비고(사용되는 곳)
kisa_20251127_A_result_ham_policyMsg.txt	사용 안함	
kisa_20251127_A_result_hamMsg_url.txt	사용	[시뮬결과전체] Sheet에 사용
kisa_20251127_A_result_hamMsg_url_35_150.txt	사용 안함	
MMSC_ORG_20251127_A.txt	사용	MMSC원문_20251127.xlsx 생성에 사용
trap_20251127_A_result_ham_policyMsg.txt	사용 안함	
trap_20251127_A_result_hamMsg_url.txt	사용	[TRAP.시뮬결과전체] Sheet에 사용
trap_20251127_A_result_hamMsg_url_35_150.txt	사용 안함	
TRAP_ORG_20251127_A.txt	사용 안함	

5. 기본적인 태깅 절차(방법) : 아래 단계를 순차적으로 진행 >> 이 절차는 일반적인 작업 순서임. 실제 작업은 p.3 부터 기술되는 [태깅 분류 작업] 절차를 확인할 것.
   1) 메시지 내용에 의한 판단 및 URL 접속 확인에 의한 판단으로 **[스팸메시지 분류, 스팸종류 판단]**
   2) 스팸으로 분류된 메시지 중 URL이 있는 메시지의 URL을 정리하여 **[URL 중복제거]**
   3) 스팸으로 분류된 메시지 중 URL에 없는 메시지에서 '공백 없는 문자열'을 추출하여 **[문자열 중복제거]**
   4) 스팸으로 분류된 메시지 중 URL이 없고, 문자열 추출도 불가능한 나머지 메시지에서 '공백 없는 문장'을 추출하여 **[문장 중복제거]**
   5) 학습에서 제외되어야 할 스팸메시지를 HAM 메시지로 변환하는 **[예외 상황 처리]**
   6) trap 데이터에도 **1)~5)의 동일한 과정을 적용**하여 작업

6. 태깅_결과_파일의 배포 : 약속된 시각이전에 메일을 통해서 배포되어야 함.
   - 평일(월요일 또는 휴일 다음날은 별도의 규칙 적용)
     10:00 배포 – 전일 16:30에 수신된 파일(20251126_B)의 결과 배포
     14:00 배포 – 당일 00:30에 수신된 파일(20251126_C)의 결과 배포
     18:00 배포 – 당일 12:30에 수신된 파일(20251127_A)의 결과 배포
   - 휴일 이후 첫 근무일의 학습 범위
     . 이틀 이상의 휴무일 경우: 마지막 휴일 분량(3개)만을 다음 첫 근무일의 2회차(17:00)에 적용, 나머지 휴일 분량은 첫 근무일의 1회차(10:00)에 적용.
     . 하루 휴무일의 경우: 휴일 분량을 첫 근무일의 2회차(14:00)에 적용.

     예시) 주말에 (금요일_B/C), (토요일 3개)(일요일 3개)날짜의 데이터를 작업하고, (월) 10:00, 14:00에 나눠서 배포.
     - 월요일 10:00에 배포될 파일 5개 : 금요일 파일 2개(금요일_B/C) + 토요일 파일 3개(_A/B/C)
     - 월요일 14:00에 배포될 파일 3개 : 일요일 파일 3개(일요일_A/B/C)

- 월요일 18:00에 배포될 파일 1개 : 월요일 파일 1개(_A : 당일 12:30 수신 파일)
- 가끔씩 학습 담당자(SKT 매니저)의 요청에 의해서 결과 파일 전달 시각이 오전으로 앞당겨지는 경우도 있음. 이 경우에는 새벽에 작업으로 대부분을 처리한 후 오전 일찍 결과물을 전달하고 있음.

7. 결과 파일인 (최종)_엑셀 파일에는 모두 12개의 Sheet가 있으나, 모든 Sheet를 학습에 사용하지 않음.
   - 학습에 필요한 "최종 데이터를 포함하는 Sheet"와 태깅 작업용 "중간 작업용 Sheet"가 있음.
   - 작업용 시트의 Format 및 작업하는 절차는 작업자의 취향대로 바꾸는 것 가능함.
   - "학습에 사용"되는 시트의 형태(엑셀의 column)는 변형 절대 불가!!(중요)

Sheet 이름	용 도	비 고
시뮬결과전체	중간 작업용	원본 txt 파일 load 용
육안분석(시뮬결과35_150)	학습에 사용	태깅 작업 & 결과물
URL중복 제거	학습에 사용	육안분석(시뮬결과35_150)에서 추출된 URL
문자문장차단등록	중간 작업용	문자열/문장 추출 작업용
문자열중복제거	학습에 사용	문자문장차단등록에서 추출된 문자열
문장중복제거	학습에 사용	문자문장차단등록에서 추출된 문장
TRAP.시뮬결과전체	중간 작업용	원본 txt 파일 load 용
TRAP.육안분석(시뮬결과35_150)	학습에 사용	태깅 작업 & 결과물
TRAP.중간작업	중간 작업용	문자열/문장 추출 작업용
TRAP.URL중복 제거	학습에 사용	TRAP.육안분석(시뮬결과35_150)에서 추출된 URL
TRAP.문자열 중복제거	학습에 사용	TRAP.중간작업에서 추출된 문자열
TRAP.문장 중복제거	학습에 사용	TRAP.중간작업에서 추출된 문장
금융.SPAM	통계 보고용	육안분석(시뮬결과35_150) 추출된 금융.spam

8. 최종적으로 전달해야 하는 결과 파일은 [MMSC스팸추출_20251127_A.xlsx], [MMSC원문_20251127.xlsx] 두 개임.
   - [MMSC스팸추출_20251127_A.xlsx] 파일에 대한 작업은 아래에 기술되는 [**태깅 분석 작업**] 과정을 적용하여 순차적으로 작업해야 함.
   - [MMSC원문_20251127_A.xlsx] 파일에 대한 작업은 [**MMSC원문_데이터 파일 처리**] 과정을 통해서 작업 필요. 익일 14:00에 한 번만 배포. ← 중요하지 않음.

태깅 분석 작업(kisa_/trap_text파일 엑셀 loading → 육안으로 스팸여부 판단 → 필요 데이터 처리 → 최종 배포 파일 만들기 순으로 작업)

- **원문파일 Loading 및 육안분석 작업**

1. 엑셀로 원문파일 Loading하기
   - Template 파일 Open : 데이터가 공백인 MMSC스팸추출_init.xlsx 파일 열기
   - [TAB]을 구분자로 해서 각 text 파일(kisa_xxx_url.txt, trap_xxx_url.txt) Open
     . **시뮬결과전체 Sheet** : kisa_20251127_A_result_hamMsg_url.txt 읽어 옴.
     . 메시지길이/URL 채우기(이하 필요한 상황에서는 다른 sheet에도 동일하게 적용)
     . **육안분석(시뮬결과35_150) Sheet** : "시뮬결과전체 Sheet"에서 메시지길이 9bytes 이상만 복사해 옴.

. **TRAP.시뮬결과전체 Sheet** : trap_20251127_A_result_hamMsg_url.txt 읽어 옴.

. **TRAP.육안분석(시뮬결과35_150) Sheet** : "TRAP.시뮬결과전체 Sheet"에서 메시지길이 9bytes 이상만 복사해 옴.

- 파일 이름을 배포파일 명으로 변경 MMSC스팸추출_20251127_A.xlsx

2. 태깅 작업하기(이하 [육안분석(시뮬결과35_150)] Sheet에서 작업)

- 아래 기본 규칙을 적용하여 분석작업 진행.

- 문자열/문장의 추출은 <과정. 6 – p.9>의 "문자열/문장 추출 기본 규칙"을 참고할 것.

육안분석(스팸/햄 구분) 기본 규칙
1. "스팸 및 햄 차단 기준.docx" 문서를 기준으로 스팸/햄 판단. 2. URL이 없는 메시지는 메시지의 내용만으로 스팸/햄 판단. 3. URL이 있는 메시지는 URL 접속 결과를 확인하여 스팸/햄 판단. (URL 접속 결과는 PC의 웹브라우저 또는 모바일을 통해서 확인) 4. 스팸일 경우, [구분]란에 'o'(영어 소문자)으로 표시하고, [분류]란에 스팸의 종류를 0~3의 숫자로 표시 * 분류 : 0(기타), 1(성인), 2(도박), 3(금융) 5. (중요) 작업 수행 과정에서 예외 처리 항목을 반영하여 스팸/햄 판단.

● (중요) 태깅 작업 시 예외 처리 – 아래 파란색 음영 2가지 경우를 모두 반영하면서 태깅해야 함.

1) URL 추출 오류 메시지 태깅 : ***URL 삭제 후 태깅*** 수행해야 함.

- URL을 삭제하기 때문에, 결과물은 **문자열 또는 문장으로 추출해야 함**(아래 각각의 예시 참고)

① 한글이 포함된 URL 추출 오류 처리

(광고)[NH]쉿!!일일 1900만 급등주bit.ly/밴드정보방선착순 마감무료거부 0801560190	bit.ly

>> URL삭제 후 보정된 URL(bit.ly/밴드정보방)을 접속하여 확인

>> 예상 결과물

- 메시지 : (광고)[NH]쉿!!일일 1900만 급등주bit.ly/밴드정보방선착순 마감무료거부0801560190
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : bit.ly/밴드정보방선착
- 문장 : 없음

(광고)※ LS머트리얼즈 ◆ IPO특별공모 신청 접수◆ http://ipo공모-lsmaterials.com 최초발행가로	lsmaterials.com

>> URL삭제 후 보정된 URL(ipo공모-lsmaterials.com)을 접속하여 확인

>> 예상 결과물

- 메시지 : (광고)※ LS머트리얼즈 ◆ IPO특별공모 신청 접수◆ http://ipo공모-lsmaterials.com 최초발행
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음

- 문자열 : 공모-lsmaterials.com
- 문장 : 없음

② 특수문자가 포함된 URL 추출 오류 처리

선물:50000[원]불 사 조 출 현5 0 0 장 획 득 추 8 4 3nwd@vin⑧4.com	4.com

>> URL삭제 후 보정된 URL(nwdavin84.com)을 접속하여 확인

>> 예상 결과물

- 메시지 : 선물:50000[원]불 사 조 출 현5 0 0 장 획 득 추 8 4 3nwd@vin⑧4.com
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : nwd@vin⑧4.com
- 문장 : 없음

③ URL 앞/뒤의 공백이 제거된 메시지에서 URL 추출 오류 처리

(광고)상위1%재무설계참가전원127%↑손익OKyoutube-dm.com재무상담무료거부08015600	okyoutube-dm.com

>> URL삭제 후 보정된 URL(youtube-dm.com)을 접속하여 확인

>> 예상 결과물

- 메시지 : (광고)상위1%재무설계참가전원127%↑손이기OKyoutube-dm.com재무상담무료거부08015600
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : OKyoutube-dm.com
- 문장 : 없음

(광고)[CJ대한통운]bit.ly/37dsGj0[29**05] 반송물품 1건확인 요청무료수신거부 0808554	bit.ly/37dsGj0[29**05

>> URL삭제 후 보정된 URL(bit.ly/37dsGj0)을 접속하여 확인

>> 예상 결과물

- 메시지 : (광고)[CJ대한통운]bit.ly/37dsGj0[29**05] 반송물품 1건확인 요청무료수신거부 0808554
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : bit.ly/37dsGj0
- 문장 : 없음

(광고)사장님 1차수령금만족하셨져?https://ko.gl/1VP2차상담대박주링크무료거부 0808	https://ko.gl/1VP2

>> URL삭제 후 보정된 URL(https://ko.gl/1VP)을 접속하여 확인

>> 예상 결과물

- 메시지 : (광고)사장님 1차수령금만족하셨져?https://ko.gl/1VP2차상담대박주링크무료거부 08085
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : https://ko.gl/1VP

- 문장 : 없음

(광고)초롱이잎@플1+1 2+2 3+3buly.kr/DPQbAJmcode: bestTEL)sunccc무료거부080855758	3buly.kr/DPQbAJmcode

>> URL삭제 후 보정된 URL(buly.kr/DPQbAJm)을 접속하여 확인

>> 예상 결과물

- 메시지 : (광고)초롱이잎@플1+1 2+2 3+3buly.kr/DPQbAJmcode: bestTEL)sunccc무료거부080855758
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : 3buly.kr/DPQbAJmcode
- 문장 : 없음

④ 메시지의 끝 부분이 잘려서 일부만 추출된 URL 추출 오류Ⅰ 처리(URL을 구분할 수 있는 상세 URL부분의 길이가 너무 짧은 경우)

인생을 바꿀 수 있는 단 하나의 비법! 우연한 가난은 없다! https://han.gl/AQ	https://han.gl/AQ

>> URL삭제 후 URL은 무시하고, 결과물은 "문장"으로 추출.

>> 예상 결과물

- 메시지 : 인생을 바꿀 수 있는 단 하나의 비법! 우연한 가난은 없다! https://han.gl/AQ
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : 없음
- 문장 : 비법!우연한가난은없다!https://han.gl/AQ

⑤ 메시지의 끝 부분이 잘려서 일부만 추출된 URL 추출 오류Ⅱ 처리(메시지의 뒷부분이 없는 메시지)

100만원이상 주식하시는 분들! 이종목을 주목하세요! https://tuney.kr/kakao.me	https://tuney.kr/kakao.me
100만원이상 주식하시는 분들! 이종목을 주목하세요! https://tuney.kr/kaka	https://tuney.kr/kaka

>> URL삭제 후 URL은 무시하고, 결과물은 "문장"으로 추출.

>> 예상 결과물(

- 메시지 : 100만원이상 주식하시는 분들!이종목을 주목하세요! https://tuney.kr/kaka
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : 없음
- 문장 : 이종목을주목하세요!https://tuney.kr/kaka

⑥ 추출로직 오류에 의한 URL 추출 오류 처리

(광고)hong.il ★(^.~)야한얘기 재밋게 해주실분 경험햇던 이야기나 주변에서 들은	hong.il

>> URL삭제 후 URL은 무시하고, 결과물은 "문장"으로 추출.

>> 예상 결과물

- 메시지 : (광고)hong.il ★(^.~)야한얘기 재밋게 해주실분 경험햇던 이야기나 주변에서 들은

- 스팸 여부 : 스팸
- 분류 : 1 (성인)
- URL : 없음
- 문자열 : 없음
- 문장 : hong.il★(^.~)야한얘기재밋게해주실분경험

⑦ URL 부분을 조작한 메시지에서 URL을 추출하지 못한 부분 보완 처리

(광고)맥스 카지노입니다. 금일 40% EVENT 많은혜택 받으시길 바랍니다. 오신는 길: mx6001.c@rn	

>> 메시지에서 도출한 URL(mx6001.com)을 접속하여 확인

>> 예상 결과물

- 메시지 : (광고)맥스 카지노입니다. 금일 40% EVENT 많은혜택 받으시길 바랍니다. 오신는 길: mx6001.c@rn
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : mx6001.c@rn
- 문장 : 없음

(광고) "토이" 랜덤 2만-20만 이용 부탁드립니다. ▶ 접 속 : TOY9898 점켬 ◆ 코 드 : KKKK ID	

>> 메시지에서 도출한 URL(toy9898.com)을 접속하여 확인

>> 예상 결과물

- 메시지 : (광고) "토이" 랜덤 2만-20만 이용 부탁드립니다. ▶ 접 속 : TOY9898 점켬 ◆ 코 드 : KKKK
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : TOY9898점켬
- 문장 : 없음

(광고) cn33ⓗⓦ.com Free*Ca [가]:[입] [30,000] [출]:[금] [100,000] 무료거부 0808706782	

>> 메시지에서 도출한 URL(cn33hw.com)을 접속하여 확인

>> 예상 결과물

- 메시지 : (광고) cn33ⓗⓦ.com Free*Ca [가]:[입] [30,000] [출]:[금] [100,000] 무료거부 0808706782
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : cn33ⓗⓦ.com
- 문장 : 없음

⑧ 새로운 유형의 URL을 추출하지 못한 오류 처리

평균 1시간 당일 수익 당일 출금 100만원 -> 200만원 https://invest99.netlify.app/	

>> 메시지에서 도출한 URL(invest99.netlify.app)로 접속하여 확인

>> 예상 결과물

- 메시지 : 평균 1시간 당일 수익 당일 출금 100만원 -> 200만원 https://invest99.netlify.app/

- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : invest99.netlify.app
- 문장 : 없음

C.S.K님 염승환의 정보방 안내 ▽ https://open-kakao.cam/use	

>> 메시지에서 도출한 URL(open-kakao.cam/use)로 접속하여 확인

>> 예상 결과물

- 메시지 : C.S.K님 염승환의 정보방 안내 ▽ https://open-kakao.cam/use
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : open-kakao.cam/use
- 문장 : 없음

⑨ URL Address로 의심되는 문자열을 포함한 메시지의 처리

(광고)나이키 대체불가♥토지노 성공으로가는 하이패스 주소 ↓ nike26. 무료거부 0808701121	

>> 메시지에서 도출한 URL(nike26.com)로 접속하여 확인

>> 예상 결과물

- 메시지 : (광고)나이키 대체불가♥토지노 성공으로가는 하이패스 주소 ↓ nike26. 무료거부 0808701121
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : 주소↓nike26.
- 문장 : 없음

2) URL 이 정상 URL인 메시지는 ***URL 삭제 후 태깅작업*** 수행.

- 결과물은 **문자열 또는 문장으로 추출**(아래 예시 참고)

① 메시지에 포함된 정상 URL(뉴스기사 또는 스패머들이 의도적으로 포함시킨 정상 URL 등)은 삭제

(광고)코리아경제티비 수익 보고 싶어요. 돈까지 내고 하고 싶지는 않아요. 그렇게 좋으면 누	newsbrite.net/129946

>> 추출된 URL(newsbrite.net/129946)은 뉴스 기사이므로 URL은 삭제 후 메시지 내용만으로 판단.

>> 예상 결과물

- 메시지 : (광고)코리아경제티비 수익 보고 싶어요. 돈까지 내고 하고 싶지는 않아요. 그렇게 좋으면...
- 스팸 여부 : 스팸
- 분류 : 2 (도박)
- URL : 없음
- 문자열 : 없음
- 문장 : 코리아경제티비수익보고싶어요.돈까지내고

3. 육안분석 작업 후처리(순서 정렬)
   - 메시지, URL, 구분 정렬을 통해서 작업한 결과를 검토하기 편하도록 sorting.

     스팸메시지를 윗쪽으로, URL이 있는 메시지를 윗쪽으로 정렬

4. 스팸 URL 검토(육안 작업)
   - 스팸메시지로 판단된 URL에 정상 URL이 포함되어 있는지 URL을 육안으로만 확인(검토)/수정

5. URL중복 제거 Sheet 작업
   - 스팸메시지의 URL/구분 데이터를 "URL중복 제거 Sheet"로 복사
   - 중복제거 수행 : 엑셀기능 "중복된 항목 제거" 사용
   - 단축 URL 분리 : 단축 URL을 포함한 URL 데이터는 별도 column으로 분리

     . [URL/길이/분류]를 각각 [T/U/V] 열로 분리

6. 문자열/문장 작업하기
   - "육안분석(시뮬결과35_150)"Sheet의 URL이 없는 스팸메시지의 [메시지]와 [분류]를 "문자문장차단등록"Sheet로 복사
   - "문자문장차단등록"Sheet의 메시지 부분 공백 제거(중복제거 및 문자열/문장 추출을 위함)
   - 문자문장차단등록"Sheet의 데이터 중복 제거
   - 아래 규칙에 따라서, 문자열과 문장을 추출(이하 [문자문장차단등록] Sheet에서 작업)

문자열/문장 추출 기본 규칙
1. 일반적인 HAM 메시지에 포함되지 않을 것으로 예상되는 부분을 문자열/문장으로 추출 2. 문자열로 우선 추출 후, 문자열 추출이 불가할 경우에는 문장으로 추출 - 문자열 : 공백이 없는 9bytes ~ 20bytes 사이로 추출 - 문장 : 공백이 없는 39bytes ~ 40bytes 사이로 추출 3. 문자열/문장에 "광고" 문구((예: (광고), 광고), [광고] 등)는 포함하면 안됨 4. 수신거부 전화번호(예: 무료거부 080xxxxxxx)만 포함하는 문자열은 추출하면 안됨

   - 메시지 Column에서 "문자열" 또는 "문장열" 추출은 아래 기준을 순서로 적용하여 작업

     ① 문자열 추출

     . 특수문자나 한글을 사용한 변형 URL 추출. 예) *Y@N@20⑤.com, jk819@@.com, 헤이접속쩜콤*

     . 한글을 사용한 변형 URL 추출. 예) *bit.ly/로얄7468, 신규이벤중.p-e.kr, 왕초문의.가기.cc*

     . 자음/모음을 분리한 문자열 추출. 예) *님BAND에초ㄷH합니다, 이터내+티브이ㄴㅅ*

     . 그 이외는 HAM 메시지에 포함되지 않을 것 같은 문자열로 추출

     ② 문자열로 추출이 어려운 경우, 문장으로 추출

     ③ 문자열이나 문장으로 추출이 어려운 경우에는 추출하지 않고 메시지를 삭제

7. [문자열 및 문장] 정리
   - "문자문장차단등록"Sheet의 [문자열]과 [분류] 데이터를 "문자열중복제거"Sheet로 복사
   - "문자열중복제거"Sheet에서 데이터 중복제거 수행
   - "문자문장차단등록"Sheet의 [문장열]과 [분류] 데이터를 "문장중복제거"Sheet로 복사
   - "문장중복제거"Sheet에서 데이터 중복제거 수행

     ※ 여기까지가 육안분석 작업의 95% 이상 완료.

8. 작업 결과 기록
   - "TRAP.문장 중복제거"Sheet의 데이터 개수 확인란에 작업 결과 기록

     . 스팸태깅 : "육안분석(시뮬결과35_150)"Sheet에서 스팸으로 분류된 개수

     . URL : "URL중복 제거"Sheet의 데이터 개수

     . 문자열 : "문자열중복제거"Sheet의 데이터 개수

     . 문장 : "문장중복제거"Sheet의 데이터 개수

- **trap_데이터 파일 처리**

  모든 trap_작업 절차는 kisa_데이터 작업과 동일한 기준을 적용하여 진행됨.

  >> kisa_데이터 처리할 때와의 차이점

  - Target Sheet는 "TRAP."으로 시작하는 Sheet에서 작업.
  - 분류(일반/성인/도박/금융)는 따로 구분하지 않음.
  - kisa_데이터와 중복 발생되는 결과값은 삭제함.

※ 스팸태깅(육안분석) 작업 1차(중간) 완료

※ 이후, "검토 및 후처리", "금융메시지 추출", "학습제외 메시지 분류" 절차를 진행해야 함.

- **검토 및 후처리**

  >> 문자열과 URL에 오판된 결과가 포함되지 않았는지를 최종 검토

  - "문자열중복제거" Sheet의 내용 확인 ← 혹시라도 HAM 문자열이 포함되지 않았나? 확인/수정
  - "URL중복 제거" Sheet의 내용 확인 ← 혹시라도 HAM URL이 포함되지 않았나? 확인/수정

- **금융 메시지 별도 추출**

  >> 분류 항목을 참고하여 금융과 관련된 스팸 메시지의 [메시지] 항목만을 "금융.SPAM"Sheet로 복사

- **학습제외_메시지 분류 작업 실행**

>> URL이 없다고 가정한다면 HAM으로 처리되어야 하는 메시지를 분류. 즉, 메시지 내용만으로는 SPAM으로 판단하지 않아도 되는 SPAM을 따로 분류하는 것.

- 대상 : "육안분석(시뮬결과35_150)"Sheet에서 URL이 있는 스팸메시지(URL 없는 메시지는 대상 아님)
- 판단 기준: URL은 무시하고, 메시지의 내용만으로는 스팸으로 판단하기 어려운 메시지를 구분

  >> 정상적인 문자열들이 ML을 통해 학습되는 것을 방지하기 위함(SPAM_URL은 이미 정리되었음).
- 분류 방법 : "육안분석(시뮬결과35_150)"Sheet의 "구분"란의 'o'를 제거하여 공백으로 만듦.
- 대상 예시 : '결혼식 관련' / '초대메시지(밴드, 카카오톡)' / '택배 관련' / '정부 사칭(국세청, 건강보험 등)' / '환불 관련' / 시사(뉴스) 내용 포함 / 반복되는 메시지(포함되는 단어가 중복학습 될 우려가 있는 메시지) 등 학습데이터에 영향을 줄 수 있다고 판단되는 메시지.
- 이 과정에서 작업된 메시지는 기존 메시지들과의 구별을 위해서

  . 메시지 부분을 옅은 붉은색 음영으로 처리 & 정렬을 수행해서 스팸과 햄 메시지 사이에 위치시킴.

  ※ 여기까지가 스팸태깅(육안분석) 작업 완료 → 최종 배포파일 생성됨.

- **[MMSC원문_데이터 파일 처리] – MMSC원문_20251126.xlsx를 사용하여 작업**

1. MMSC_ORG_20251127_A.txt 파일을 Loading 하여 "음성스팸"과 "문자스팸"으로 Sheet를 따로 분류.
   - 원본(텍스트) 파일에는 [저장일자/수신일자/발신번호/수신번호/회신번호/메시지/엔터제거카운트]가 [TAB]으로 구분되어 있음.
   - 메시지의 내용이 [음성 스팸신고]인 메시지와 그 이외의 메시지를 구분하여 각 Sheet로 Copy & Paste.
2. 데이터의 개수를 "통계"Sheet에 기록
3. _A, _B, _C까지 누적하여 MMSC원문_20251127.xlsx 파일로 최종 생성